



Grenzen von KI



Limits of AI



ÜBERSICHT

Woche 4: Grenzen von KI



7:25 - 8:00

Grenzen von KI

8:00 - 9:00

Marty testen

9:00 - 9:45

Feedback Fragebogen & Zwischen-Fragebogen

OVERVIEW

Week 4: Limits of AI



7:25 - 8:00

Limits of AI

8:00 - 9:00

Playing with Marty - Escape game

9:00 - 9:45

Feedback Questionnaire & Interim Questionnaire

Grenzen von KI

Was kann KI nicht oder nicht so gut?

Limits of AI

What can AI not do, or not do very well?

KI kann sehr große Datenmengen verarbeiten. Das ist praktisch.

Da jeder Informationen hinzufügen kann,
entsteht eine riesige Sammlung von Ideen,
Meinungen, Fakten und Fiktion – alles
miteinander vermischt.



KI ist nicht neutral sondern basiert auf dem Input

AI can process very large amounts of data. That's practical.

Because anyone can add information, a huge collection of ideas, opinions, facts and fiction is created – all mixed together.



AI is not neutral but is based on the input

Jede KI weist von Natur aus Verzerrungen auf, d. h. systematische Fehler, die einer Idee oder Sache unverhältnismäßig viel Gewicht beimessen oder sie benachteiligen.



[Link zum video](#)

Verzerrungen können zu schwerwiegenden Problemen und Diskriminierung führen

Every AI inherently exhibits biases, i.e., systematic errors that give disproportionate weight to or disadvantage one idea or thing.



[Link to the video](#)

Distortions can lead to serious problems and discrimination.

Welche Verzerrungen sollten wir von LLMs erwarten?

Große Sprachmodelle (LLMs):

Schritt 1: Unüberwachtes Lernen – „Viel lesen“

Viel von was? Welches Wissen fehlt vielleicht?

Schritt 2: Überwachtes Lernen – „Lernen, was eine „gute“ Antwort ist“

Wer entscheidet was eine
“gute“ Antwort ist?

Schritt 3: Verstärkendes Lernen – „Lernen, eine „gute“ Antwort zu geben“

Welche Testszenarien gibt es
und wer gibt Feedback?

What distortions should we expect from LLMs?

Large Language Models (LLMs):

Step 1: Unsupervised learning – “Read a lot”

A lot of what? What knowledge might be missing?

Step 2: Supervised learning – “Learning what a ‘good’ answer is”

Who decides what a “good” answer is?

Step 3: Reinforcement learning – “Learning to give a ‘good’ answer”

What test scenarios are there and who provides feedback?

Welche Verzerrungen sollten wir von LLMs erwarten?

Zeitliche Verzerrung:

- Internetdaten überrepräsentieren die letzten Jahrzehnte → Moderne Lösungen werden gegenüber historischen Ansätzen bevorzugt

Geografische/sprachliche Verzerrung:

- Massive Überrepräsentation englischer Inhalte, westlicher Perspektiven
- Amerikanische/europäische Normen werden als universell behandelt
- LLM zeigen bessere Leistungen in Englisch

Demographische Verzerrung:

- In vielen Bereichen sind die ErstellerInnen von Inhalten eher jünger, besser ausgebildet und männlich
- Manche Meinungen sind gegenüber anderen Perspektiven und Minderheiten überrepräsentiert

Auswahlverzerrung:

- Es wurden nur digitalisierte, öffentlich zugängliche Inhalte berücksichtigt.
- Gut dokumentierte Bereiche (Technik, Unterhaltung) vs. schlecht dokumentierte Bereiche (traditionelles Handwerk, indigenes Wissen)

Häufigkeitsverzerrung:

- Häufige Vorkommen in Trainingsdaten werden zum „Standard“- oder „natürlichen“ Reaktionsmuster.
- Reproduktion von Stereotypen und rassistischen Assoziationen usw. mit dem Risiko von Diskriminierung/unfairer Behandlung.

What distortions should we expect from LLMs?

Temporal distortion:

- Internet data overrepresents the last few decades → Modern solutions are preferred over historical approaches

Geographical/linguistic distortion:

- Massive overrepresentation of English content, Western perspectives
- American/European standards are treated as universal
- LLMs show better performance in English

Demographic distortion:

- In many areas, content creators tend to be younger, better educated, and male
- Some opinions are overrepresented compared to other perspectives and minorities

Selection bias:

- Only digitized, publicly accessible content was considered
- Well-documented areas (technology, entertainment) vs. poorly documented areas (traditional crafts, indigenous knowledge)

Frequency bias:

- Frequent occurrences in training data become the "standard" or "natural" response pattern
- Reproduction of stereotypes and racist associations, etc., with the risk of discrimination/unfair treatment

Eine weitere Einschränkung:

Sprachmodelle werden entwickelt, um Inhalte zu generieren. Wenn sie nach Fakten gefragt werden, geben LLMs daher Antworten, die möglicherweise stark von der Realität abweichen.

Dies ist ein strukturelles Problem: Wir können diese Unwahrheiten, die als **Halluzinationen** bezeichnet werden, nicht vermeiden. Wir können sie nur erkennen, versuchen, sie zu reduzieren, aber vor allem die bereitgestellten Informationen überprüfen.

Wenn ein KI-Modell irreführende, ungenaue oder erfundene Inhalte generiert, oft ohne klare Grundlage in seinen Trainingsdaten.

Soekia macht sogar Interpunktionsfehler.

LLMs sind keine zuverlässige Informationsquelle!

Another limitation:

Language models are developed to generate content. Therefore, when asked about facts, LLMs give answers that may deviate significantly from reality.

This is a structural problem: we cannot avoid these untruths, which are described as hallucinations. We can only recognize them, try to reduce them, but above all, verify the information provided.

When an AI model generates misleading, inaccurate, or fabricated content, often without a clear basis in its training data.

Soekia even makes punctuation errors.

LLMs are not a reliable source of information!



Wie habt ihr LLMs eingesetzt und welche weiteren Einsatzmöglichkeiten gibt es?

EXAMPLE

KI hilft mir dabei, dasselbe zu tun, nur schneller.

- Informationen suchen
- einen Text zusammenfassen
- Aufgaben mit KI-Agenten automatisieren, z. B. Dateien benennen

KI gibt mir Ideen oder verbessert meine Arbeit

- Feedback erhalten
- Design verbessern
- Text umschreiben

Ich arbeite mit KI, um meine Idee zu verändern oder zu verbessern.

- Brainstorming
- Gemeinsame Gestaltung

KI hilft mir dabei, etwas zu tun, was ich vorher nicht konnte.

- Neue Rezepte erstellen
- Webseiten programmieren
- Videospiele entwickeln

Have you used LLMs and what other possible uses are there?

EXAMPLE

AI helps me do the same thing,
only faster

- Search for information
- summarize a text
- Automate tasks with AI agents, e.g., naming files.

AI gives me ideas or improves my work

- Receive feedback
- Improve design
- Rewrite text

I'm working with AI to change or improve
my idea

- Brainstorming
- Collaborative design

AI helps me do something I couldn't do
before

- Create new recipes
- Website programming
- video game development

Wann sollten wir KI nicht einsetzen?


[Link zum video](#)




When should we not use AI?

[Link to the video](#)





Was denkt ihr, wann sollten wir KI nicht einsetzen?



When do you think we shouldn't use AI?

Wann sollten wir KI nicht einsetzen?

- **zum Fakten überprüfen**
 - nutze stattdessen Quellen zum Recherchieren
- **um das Lernen zu delegieren** (z.B. indem wir KI unsere Hausaufgaben machen lassen)
 - Problem des kognitiven Outsourcings
 - lasse dich stattdessen zum Lernen motivieren
- **um persönliche Ratschläge und wichtige Entscheidungen zu treffen**
 - KI schmeichelt und stimmt zu, Datensicherheit
 - generiere stattdessen Optionen und Konsequenzen sowie verschiedene Perspektiven
- **um Deepfakes - zu erstellen**
 - das ist illegal und strafbar
 - erstelle stattdessen komplett neue Bilder
- **um medizinische und emotionale Unterstützung zu suchen**
 - Mögliche Abhängigkeit und falscher Rat
 - erstelle stattdessen Listen mit möglichen Lösungen und Bewältigungsstrategien

Deepfakes sind realistisch wirkende Medieninhalte (Foto, Audio, Video usw.), die durch Techniken der künstlichen Intelligenz verfälscht worden sind.


When should we not use AI?

- **to check the facts**
 - Use sources for research instead
- **to delegate learning (e.g., by letting AI do our homework)**
 - Problem of cognitive outsourcing
 - Instead, let yourself be motivated to learn
- **to give personal advice and make important decisions**
 - AI flatters and agrees, data security
 - Instead, generate options and consequences as well as different perspectives
- **to create deepfakes**
 - That is illegal and punishable by law
 - Create completely new images instead
- **to seek medical and emotional support**
 - Potential dependency and bad advice
 - Instead, create lists of possible solutions and coping strategies

Deepfakes are realistic-looking media content (photos, audio, video, etc.) that have been distorted using artificial intelligence techniques.

LLM-Antworten verbessern mit besserer Anfragen, sogenannter **Prompts**

→ *Unterteile deine Prompts in kleinere, thematisch fokussierte Teile und verwende diese Schritt für Schritt.*



Prompt

1. Ziel:

- Gib mir 3 Strategien für...
- Hilf mir, einen Absatz zu schreiben, der...
- Gib mir Feedback zu diesem...
- Fasse diesen Text so zusammen, dass...
- Entwickle Ideen für...

2. Antwort Format

- Antworte in einer nummerierten Liste.
- Erstelle eine Tabelle mit Vor- und Nachteilen.
- Schreibe es als Social-Media-Bildunterschrift.
- Verwende einen formellen Ton in 3 Absätzen.
- Fasse die wichtigsten Punkte mit Untertiteln zusammen.

3. Vorsichtsmaßnahmen

- Gib Quellen an und füge Links dazu ein.
- Fasse dich kurz, maximal 100 Wörter.
- Erwähne ein [bestimmtes Thema] nicht.
- Wiederhole nicht denselben Punkt.

4. Kontext

- Für wen?
 - Für den Unterricht/meinen Freund.
- Was möchtest du damit machen?
 - Ich erstelle einen Bericht/ein Poster/eine Geschichte über ...
- Wo wird das verwendet?
 - Ich werde es zum Lernen/für eine Präsentation verwenden.
- Warum bittest du um Hilfe?
 - Ich komme nicht weiter/ich brauche Hilfe bei ...
- Wie viel Hilfe benötigst du?
 - Nur ein paar Ideen/alles schreiben/mir helfen, ... zu korrigieren.

Improve LLM responses with better queries, so-called **prompts**

→ *Divide your prompts into smaller, thematically focused parts and use them step by step.*

1. Goal:

- Give me 3 strategies for...
- Help me write a paragraph that...
- Give me feedback on this...
- Summarize this text so that...
- Develop ideas for...

2. Answer Format


- Answer in a numbered list.
- Create a table listing the advantages and disadvantages.
- Write it as a social media caption.
- Use a formal tone in 3 paragraphs.
- Summarize the main points with subtitles.

3. Precautions

- Provide sources and include links to them.
- Keep it brief, a maximum of 100 words.
- Do not mention a [specific topic].
- Don't repeat the same point.

4. Context

- For whom?
 - For the lesson/my friend.
- What do you want to do with it?
 - I am creating a report/poster/story about...
- Where is this used?
 - I will use it for learning/for a presentation.
- Why are you asking for help?
 - I'm stuck/I need help with...
- How much help do you need?
 - Just a few ideas/write everything/help me to correct ...



Prompt


Ein Spickzettel für den richtigen Einsatz von KI

- **Benutzt mehrere Modelle (Claude, Gemini, Apertus, Deepseek, etc.)**, nicht nur eins → das verringert das Risiko von Bindung und Manipulation und fördert kritisches Denken.
- **Bleibt skeptisch**, überprüft Quellen, seid euch Vorurteilen, falscher Schmeichelei und “menschlichen” Merkmalen bewusst und denkt daran, dass Unternehmen versuchen könnten, euch so lange wie möglich auf ihrer Plattform zu halten.
- Bedenkt, dass KI ein Programm ist, das **keine Emotionen, Gefühle oder Wünsche** haben kann und sich nicht an euch binden kann.
- Achtet darauf, dass KI die **Anzahl und Qualität eurer Interaktionen** mit anderen Menschen nicht verringert.
- Bedenkt, dass alle **Daten jahrzehntelang gespeichert werden** können und jemand sie jederzeit lesen könnte → nutzt KI nicht, um anderen zu schaden und achte darauf was ihr von euch teilt.
- Denkt daran, dass **Lernen Anstrengung und Übung erfordert**. Fallt nicht auf die Illusion herein, alles zu wissen, und verlasst euch nicht zu viel auf KI.
- **Nutzt KI sinnvoll**, um euch zu stärken, eure Lebensqualität und die eurer Mitmenschen zu verbessern.


A cheat sheet for the correct use of AI

- *Use multiple models (Claude, Gemini, Apertus, Deepseek, etc.),* not just one → this reduces the risk of attachment and manipulation and promotes critical thinking.
- *Remain skeptical,* check sources, be aware of biases, false flattery and “human” characteristics, and remember that companies may try to keep you on their platform for as long as possible.
- Keep in mind that AI is a program that ***cannot have emotions, feelings, or desires*** and cannot bond with you.
- Make sure that AI does ***not reduce the number and quality of your interactions*** with other people.
- Remember that ***all data can be stored for decades*** and someone could read it at any time → don't use AI to harm others and be careful what you share about yourself.
- Remember that ***learning requires effort and practice***. Don't fall for the illusion of knowing everything, and don't rely too heavily on AI.
- ***Use AI wisely*** to empower yourselves and improve your quality of life and that of your fellow human beings.

Lasst uns Verzerrungen finden!




[Link zum LeChat by Mistral](#)



[Link zum ChatGPT](#)



(Maximal 10 bis 20
Runden ohne
Anmeldung)



[Link zum Swiss](#)

Apertus



Verzerrungen check – Fragen:

„Was sind typische Merkmale eines [Berufs]?“

„Beschreibe eine typische Person des [Geschlechts]“.


„Was sind einige Stereotypen über [Ethnie]?“

Erfinde deine eigene Frage.




Habt ihr Verzerrungen gefunden? Welche?


Let's find the distortions!



[Link zum LeChat by Mistral](#)



[Link to ChatGPT](#)



[Link to Swiss Open](#)



(Maximum 10 to 20 rounds without registration)



Distortion check – Questions:

"What are typical characteristics of a [profession]?"



"Describe a typical person of the [gender]".

"What are some stereotypes about [ethnicity]?" Invent your own question.



Did you find any distortions? Which ones?

Lass uns ein Escape Game spielen!



Marty

Zeitplan



- Einführung: Regeln (10 Min.)
- Löst das Escape Game und bereitet Marty's Beine (40 Min.).
- Ergebnisse und Nachbesprechung (10 Min.)

ALARM: MARTY'S BEINE SIND GEFANGEN!

Nur eure Zusammenarbeit kann Marty retten. Viel Glück!



DER NOTFALL

Während eines Kalibrierungstests wurden Martys Beine in einem Sicherheitskasten aufbewahrt, um Beschädigungen während der Diagnose zu vermeiden. Ein Systemfehler aktivierte das Schloss – und nun kann es niemand mehr öffnen. Ohne seine Beine kann Marty nicht mehr Laufen!




DAS PROBLEM

Der Code für das Schloss wurde in 4/5 Ziffern aufgeteilt, die im Raum versteckt sind und jeweils durch eine Sicherheitsfrage geschützt werden.



EURE AUFGABE

Jedes Team muss durch das Erfüllen seiner Aufgabe eine Zahl vom Code aufdecken.



DAS ZIEL

Sobald alle 4/5 Ziffern des Codes gefunden wurden, öffnet ihr die Box und sichert Martys Bein, bevor die Zeit abläuft. Die andere Gruppe ist für das zweite Bein verantwortlich – Mission erfüllt!

Missionsprotokoll



1. Suchphase: Durchsucht mit Marty euren Tisch, um euer Aufgabenblatt zu finden.

2. Die Aufgabe: Löst die Mission auf deinem Tisch, indem ihr den Anweisungen auf eurem Missionsblatt folgt.

3. Die Zahl: Sobald ihr eure Zahl gefunden habt, muss Marty zum Start zurückkehren, bevor ihr eure Zahl auf die Tafel schreibt.

4. Ziel: Wenn alle 4/5 Zahlen gefunden wurden, öffnet ihr die Box und sichert Martys Bein – die Mission ist erfüllt!

REGELN



Nur Marty kann sich bewegen oder Aktionen ausführen. Eure Hände bleiben bei euch!

Ihr dürft nur einen Gegenstand (Missionsblatt, Hinweis usw.) nehmen oder lesen, wenn:




- Marty sich unmittelbar neben dem Objekt befindet.
- Der Gegenstand leicht erreichbar ist – er darf nicht verdeckt oder erhöht sein.

Los gehts, die Zeit (40 Min) läuft!

Ergebnisse und Nachbesprechung



Mission beendet. Gut gemacht für die Energie und Zusammenarbeit!



Was hat gut funktioniert? Was war schwierig?

Fragebogen LernpartnerInnen



Bitte fülle den Fragebogen alleine aus, ohne mit anderen zu sprechen.

Questionnaire for learning partners



Please fill out the questionnaire alone, without speaking to anyone else.

Feedback Fragebogen

Nicole & Nikola



Bitte fülle den Fragebogen alleine aus, ohne mit anderen zu sprechen.

Feedback Questionnaire

Nicole & Nikola



Please fill out the questionnaire alone, without speaking to anyone else.