


Grenzen von KI



ÜBERSICHT

Woche 4: Grenzen von KI



7:25 - 8:00

Grenzen von KI

8:00 - 9:00

Marty testen

9:00 - 9:45

Feedback Fragebogen & Zwischen-Fragebogen

Grenzen von KI

Was kann KI nicht oder nicht so gut?

KI kann sehr große Datenmengen verarbeiten. Das ist praktisch.

Da jeder Informationen hinzufügen kann,
entsteht eine riesige Sammlung von Ideen,
Meinungen, Fakten und Fiktion – alles
miteinander vermischt.



KI ist nicht neutral sondern basiert auf dem Input

Jede KI weist von Natur aus Verzerrungen auf, d. h. systematische Fehler, die einer Idee oder Sache unverhältnismäßig viel Gewicht beimessen oder sie benachteiligen.



[Link zum video](#)

Verzerrungen können zu schwerwiegenden Problemen und Diskriminierung führen

Welche Verzerrungen sollten wir von LLMs erwarten?

Große Sprachmodelle (LLMs):

Schritt 1: Unüberwachtes Lernen – „Viel lesen“

Viel von was? Welches Wissen fehlt vielleicht?

Schritt 2: Überwachtes Lernen – „Lernen, was eine „gute“ Antwort ist“

Wer entscheidet was eine
“gute“ Antwort ist?

Schritt 3: Verstärkendes Lernen – „Lernen, eine „gute“ Antwort zu geben“

Welche Testszenarien gibt es
und wer gibt Feedback?

Welche Verzerrungen sollten wir von LLMs erwarten?

Zeitliche Verzerrung:

- Internetdaten überrepräsentieren die letzten Jahrzehnte → Moderne Lösungen werden gegenüber historischen Ansätzen bevorzugt

Geografische/sprachliche Verzerrung:

- Massive Überrepräsentation englischer Inhalte, westlicher Perspektiven
- Amerikanische/europäische Normen werden als universell behandelt
- LLM zeigen bessere Leistungen in Englisch

Demographische Verzerrung:

- In vielen Bereichen sind die ErstellerInnen von Inhalten eher jünger, besser ausgebildet und männlich
- Manche Meinungen sind gegenüber anderen Perspektiven und Minderheiten überrepräsentiert

Auswahlverzerrung:

- Es wurden nur digitalisierte, öffentlich zugängliche Inhalte berücksichtigt.
- Gut dokumentierte Bereiche (Technik, Unterhaltung) vs. schlecht dokumentierte Bereiche (traditionelles Handwerk, indigenes Wissen)

Häufigkeitsverzerrung:

- Häufige Vorkommen in Trainingsdaten werden zum „Standard“- oder „natürlichen“ Reaktionsmuster.
- Reproduktion von Stereotypen und rassistischen Assoziationen usw. mit dem Risiko von Diskriminierung/unfairer Behandlung.

Eine weitere Einschränkung:

Sprachmodelle werden entwickelt, um Inhalte zu generieren. Wenn sie nach Fakten gefragt werden, geben LLMs daher Antworten, die möglicherweise stark von der Realität abweichen.

Dies ist ein strukturelles Problem: Wir können diese Unwahrheiten, die als **Halluzinationen** bezeichnet werden, nicht vermeiden. Wir können sie nur erkennen, versuchen, sie zu reduzieren, aber vor allem die bereitgestellten Informationen überprüfen.

Wenn ein KI-Modell irreführende, ungenaue oder erfundene Inhalte generiert, oft ohne klare Grundlage in seinen Trainingsdaten.

Soekia macht sogar Interpunktionsfehler.

LLMs sind keine zuverlässige Informationsquelle!



Wie habt ihr LLMs eingesetzt und welche weiteren Einsatzmöglichkeiten gibt es?

EXAMPLE

KI hilft mir dabei, dasselbe zu tun, nur schneller.

- Informationen suchen
- einen Text zusammenfassen
- Aufgaben mit KI-Agenten automatisieren, z. B. Dateien benennen

KI gibt mir Ideen oder verbessert meine Arbeit

- Feedback erhalten
- Design verbessern
- Text umschreiben

Ich arbeite mit KI, um meine Idee zu verändern oder zu verbessern.

- Brainstorming
- Gemeinsame Gestaltung


KI hilft mir dabei, etwas zu tun, was ich vorher nicht konnte.

- Neue Rezepte erstellen
- Webseiten programmieren
- Videospiele entwickeln

Wann sollten wir KI nicht einsetzen?

[Link zum video](#)





Was denkt ihr, wann sollten wir KI nicht einsetzen?


Wann sollten wir KI nicht einsetzen?

- **zum Fakten überprüfen**
 - nutze stattdessen Quellen zum Recherchieren
- **um das Lernen zu delegieren** (z.B. indem wir KI unsere Hausaufgaben machen lassen)
 - Problem des kognitiven Outsourcings
 - lasse dich stattdessen zum Lernen motivieren
- **um persönliche Ratschläge und wichtige Entscheidungen zu treffen**
 - KI schmeichelt und stimmt zu, Datensicherheit
 - generiere stattdessen Optionen und Konsequenzen sowie verschiedene Perspektiven
- **um Deepfakes - zu erstellen**
 - das ist illegal und strafbar
 - erstelle stattdessen komplett neue Bilder
- **um medizinische und emotionale Unterstützung zu suchen**
 - Mögliche Abhängigkeit und falscher Rat
 - erstelle stattdessen Listen mit möglichen Lösungen und Bewältigungsstrategien

Deepfakes sind realistisch wirkende Medieninhalte (Foto, Audio, Video usw.), die durch Techniken der künstlichen Intelligenz verfälscht worden sind.

LLM-Antworten verbessern mit besserer Anfragen, sogenannter **Prompts**

→ *Unterteile deine Prompts in kleinere, thematisch fokussierte Teile und verwende diese Schritt für Schritt.*



Prompt

1. Ziel:

- Gib mir 3 Strategien für...
- Hilf mir, einen Absatz zu schreiben, der...
- Gib mir Feedback zu diesem...
- Fasse diesen Text so zusammen, dass...
- Entwickle Ideen für...

2. Antwort Format

- Antworte in einer nummerierten Liste.
- Erstelle eine Tabelle mit Vor- und Nachteilen.
- Schreibe es als Social-Media-Bildunterschrift.
- Verwende einen formellen Ton in 3 Absätzen.
- Fasse die wichtigsten Punkte mit Untertiteln zusammen.

3. Vorsichtsmaßnahmen

- Gib Quellen an und füge Links dazu ein.
- Fasse dich kurz, maximal 100 Wörter.
- Erwähne ein [bestimmtes Thema] nicht.
- Wiederhole nicht denselben Punkt.


4. Kontext

- Für wen?
 - Für den Unterricht/meinen Freund.
- Was möchtest du damit machen?
 - Ich erstelle einen Bericht/ein Poster/eine Geschichte über ...
- Wo wird das verwendet?
 - Ich werde es zum Lernen/für eine Präsentation verwenden.
- Warum bittest du um Hilfe?
 - Ich komme nicht weiter/ich brauche Hilfe bei ...
- Wie viel Hilfe benötigst du?
 - Nur ein paar Ideen/alles schreiben/mir helfen, ... zu korrigieren.


Ein Spickzettel für den richtigen Einsatz von KI

- **Benutzt mehrere Modelle (Claude, Gemini, Apertus, Deepseek, etc.)**, nicht nur eins → das verringert das Risiko von Bindung und Manipulation und fördert kritisches Denken.
- **Bleibt skeptisch**, überprüft Quellen, seid euch Vorurteilen, falscher Schmeichelei und “menschlichen” Merkmalen bewusst und denkt daran, dass Unternehmen versuchen könnten, euch so lange wie möglich auf ihrer Plattform zu halten.
- Bedenkt, dass KI ein Programm ist, das **keine Emotionen, Gefühle oder Wünsche** haben kann und sich nicht an euch binden kann.
- Achtet darauf, dass KI die **Anzahl und Qualität eurer Interaktionen** mit anderen Menschen nicht verringert.
- Bedenkt, dass alle **Daten jahrzehntelang gespeichert werden** können und jemand sie jederzeit lesen könnte → nutzt KI nicht, um anderen zu schaden und achte darauf was ihr von euch teilt.
- Denkt daran, dass **Lernen Anstrengung und Übung erfordert**. Fallt nicht auf die Illusion herein, alles zu wissen, und verlasst euch nicht zu viel auf KI.
- **Nutzt KI sinnvoll**, um euch zu stärken, eure Lebensqualität und die eurer Mitmenschen zu verbessern.

Lasst uns Verzerrungen finden!




[Link zum LeChat by Mistral](#)



[Link zum ChatGPT](#)



(Maximal 10 bis 20
Runden ohne
Anmeldung)



[Link zum Swiss](#)

Apertus



Verzerrungen check – Fragen:

„Was sind typische Merkmale eines [Berufs]?“

„Beschreibe eine typische Person des [Geschlechts]“.


„Was sind einige Stereotypen über [Ethnie]?“

Erfinde deine eigene Frage.



Habt ihr Verzerrungen gefunden? Welche?

Marty testen



Marty

Verbindet Marty mit dem Laptop oder Ipad.


Öffnet den Guide der euch
erklärt, wie ihr euch mit
Marty verbinden könnt.
(Auf dem iPad braucht ihr
die App ***Marty the robot V2***)

Befolgt dann die Anweisung
um die Motoren zu
Kalibrieren.



Öffnet den Controller

1. Testet ob Marty sich bewegt. Testet Arme, Beine und Augen!
2. Wenn etwas nicht funktioniert, findet heraus warum und repariert es.



Diskussion



Habt ihr Probleme gefunden? Welche Probleme hattet ihr und konntet ihr sie beheben?

Fragebogen LernpartnerInnen



Bitte fülle den Fragebogen alleine aus, ohne mit anderen zu sprechen.

Feedback Fragebogen

Nicole & Nikola



Bitte fülle den Fragebogen alleine aus, ohne mit anderen zu sprechen.